

RegEx (Regular Expression) মাস্টার গাইড

একদম নতুনদের জন্য বাস্তব জীবনভিত্তিক সহজ ও সম্পূর্ণ নির্দেশিকা

RegEx আসলে কী এবং কেন শিখবেন?

RegEx (Regular Expression) হলো টেক্সট প্রসেসিং এবং সার্চ করার একটি অত্যন্ত শক্তিশালী সাংকেতিক ভাষা। সাধারণ **Ctrl + F** দিয়ে আপনি শুধু নির্দিষ্ট একটি শব্দ খুঁজতে পারেন। কিন্তু RegEx-এর মাধ্যমে আপনি টেক্সটের **প্যাটার্ন বা ধরণ** ধরে অনুসন্ধান করতে পারবেন। যেমন: কোনো ডকুমেন্টের সব মোবাইল নম্বর, ইমেইল আইডি, বা নির্দিষ্ট ফরম্যাটের তারিখ এক নিমেষে খুঁজে বের করা বা বদলে ফেলা।

১. বেসিক বিল্ডিং ব্লকস (মৌলিক প্রতীকসমূহ)

RegEx শেখার প্রথম ধাপ হলো এর মূল বর্ণমালা বা প্রতীকগুলো চিনে নেওয়া:

চিহ্ন (Symbol)	অর্থ (Meaning)	ব্যাখ্যা ও উদাহরণ
\d	Digit (সংখ্যা)	যেকোনো একটি সংখ্যা (0 থেকে 9)। যেমন: \d খুঁজে পাবে 5 ।
\D	Non-digit (সংখ্যা নয়)	সংখ্যা ছাড়া যেকোনো বর্ণ বা চিহ্ন।
\w	Word character (শব্দের বর্ণ)	যেকোনো বর্ণ (A-Z, a-z), সংখ্যা (0-9) এবং আন্ডারস্কোর (_)।
\W	Non-word character	অক্ষর/সংখ্যা/আন্ডারস্কোর ছাড়া বাকি সব চিহ্ন (স্পেস, @ , # , \$, ইত্যাদি)।
\s	Whitespace (স্পেস)	স্পেস (Space), ট্যাব (Tab) বা নতুন লাইন (Newline)।
.	Any character (যেকোনো কিছু)	নতুন লাইন ছাড়া যেকোনো একটি বর্ণ, সংখ্যা বা প্রতীক।

২. কোয়ান্টিফায়ার (পরিমাণ নির্ধারণকারী চিহ্ন)

কোনো চিহ্ন কতবার থাকবে, তা নির্ধারণ করতে নিচের কোয়ান্টিফায়ারগুলো ব্যবহার করা হয়:

কোয়ান্টিফায়ার	অর্থ	উদাহরণ
+	১ বা তার বেশি (At least 1)	\d+ মানে হলো অন্তত ১টি বা পর পর একাধিক সংখ্যা (যেমন: 1234)।
*	০ বা তার বেশি (0 or more)	উপস্থিত থাকতেও পারে, নাও থাকতে পারে বা অনেকবার থাকতে পারে।
?	০ বা ১ বার (Optional)	ঐচ্ছিক উপাদান। যেমন: colou?r দিয়ে color এবং colour দুটিই মিলবে।
{n}	ঠিক n বার	\d{4} মানে ঠিক ৪টি সংখ্যা (যেমন: 2026)।
{n,m}	n থেকে m বার	\d{2,4} মানে ২টি থেকে ৪টি সংখ্যার জোট।

৩. বাস্তব জীবনের ৪টি দারুণ উদাহরণ

উদাহরণ ১: বাংলাদেশের মোবাইল নম্বর শনাক্তকরণ

লক্ষ্য: একটি লেখায় থাকা বাংলাদেশি মোবাইল নম্বরগুলো (যেমন: 01712345678 বা 01800000000) খুঁজে বের করা।

Regex প্যাটার্ন: **01[3-9]\d{8}**

প্যাটার্নের ব্যবচ্ছেদ:

- 01** - নম্বরটি অবশ্যই '01' দিয়ে শুরু হতে হবে।
- [3-9]** - ৩য় নম্বরটি ৩ থেকে ৯-এর মধ্যে হতে হবে (কারণ বাংলাদেশে 010, 011, 012 সাধারণত ব্যবহৃত হয় না)।
- \d{8}** - এরপর আরও ঠিক ৮টি সংখ্যা থাকবে। (মোট ১১ ডিজিট)।

ফলাফল:

- 01712345678** (ম্যাচ করেছে)
- 01987654321** (ম্যাচ করেছে)
- 01234567890** (ম্যাচ করবে না - ৩য় ডিজিট '2')
- 01712345** (ম্যাচ করবে না - ডিজিট কম)

উদাহরণ ২: ইমেইল ঠিকানা (Email Address) ফিল্টার করা

লক্ষ্য: যেকোনো বৈধ ইমেইল অ্যাড্রেস (যেমন: `rahim12@gmail.com`) বের করা।

RegEx প্যাটার্ন: `[\w.-]+@[ \w.-]+\.\w+`

প্যাটার্নের ব্যবচ্ছেদ:

- `[\w.-]+` - @ চিহ্নের আগে এক বা একাধিক অক্ষর, সংখ্যা, ডট বা হাইফেন।
- `@` - একটি অবশ্যই থাকা আবশ্যিক '@' চিহ্ন।
- `[\w.-]+` - ডোমেইন নাম (যেমন: gmail, yahoo)।
- `\.` - একটি আসল ডট (.) চিহ্ন (যেহেতু ডট নিজে একটি স্পেশাল ক্যারেক্টার, তাই ব্যাকস্ল্যাশ দেওয়া হয়েছে)।
- `\w+` - ডোমেইন এক্সটেনশন (যেমন: com, org, net)।

ফলাফল:

- `karim.test_1@gmail.com` (ম্যাচ করেছে)
- `info@company.com.bd` (ম্যাচ করেছে)
- `invalid-email@` (ম্যাচ করবে না - ডোমেইন নেই)

উদাহরণ ৩: তারিখ (Date Format) শনাক্ত করা

লক্ষ্য: DD-MM-YYYY বা DD/MM/YYYY ফরম্যাটের তারিখ খোঁজা (যেমন: 15-08-2026)।

RegEx প্যাটার্ন: `\d{2}[-/]\d{2}[-/]\d{4}`

প্যাটার্নের ব্যবচ্ছেদ:

- `\d{2}` - ২ ডিজিটের দিন (যেমন: 15)।
- `[-/]` - একটি হাইফেন (-) অথবা একটি স্ল্যাশ (/) চিহ্ন।
- `\d{2}` - ২ ডিজিটের মাস (যেমন: 08)।
- `[-/]` - পুনরায় হাইফেন (-) অথবা স্ল্যাশ (/) চিহ্ন।
- `\d{4}` - ৪ ডিজিটের বছর (যেমন: 2026)।

ফলাফল:

- `15-08-2026` (ম্যাচ করেছে)
- `01/12/2025` (ম্যাচ করেছে)
- `2026-08-15` (ম্যাচ করবে না - ফরম্যাট ভিন্ন)

উদাহরণ ৪: স্ট্রিং পাসওয়ার্ড যাচাইকরণ (Validation)

লক্ষ্য: একটি পাসওয়ার্ডে অন্তত একটি ছোট হাতের অক্ষর, একটি বড় হাতের অক্ষর, একটি সংখ্যা এবং ন্যূনতম ৮টি অক্ষর আছে কি না চেক করা।

RegEx প্যাটার্ন: `^(?=.*[a-z])(?=.*[A-Z])(?=.*\d){8,}$`

প্যাটার্নের ব্যবচ্ছেদ:

- `^` - লেখার শুরু এবং `$` - লেখার শেষ।
- `(?=.*[a-z])` - অন্তত একটি ছোট হাতের অক্ষর (a-z) থাকতে হবে।
- `(?=.*[A-Z])` - অন্তত একটি বড় হাতের অক্ষর (A-Z) থাকতে হবে।
- `(?=.*\d)` - অন্তত একটি সংখ্যা (0-9) থাকতে হবে।
- `{8,}` - মোট দৈর্ঘ্য কমপক্ষে ৮টি ক্যারেক্টার হতে হবে।

৪. পজিশনিং বা বাউন্ডারি চিহ্ন (Anchors)

লেখার কোন জায়গায় প্যাটার্নটি থাকবে তা নির্দিষ্ট করার চিহ্ন:

- `^` (Caret): লাইনের **শুরুতে** ম্যাচ করায়। যেমন: `^Hello` (লাইনটি Hello দিয়ে শুরু হতে হবে)।
- `$` (Dollar): লাইনের **শেষে** ম্যাচ করায়। যেমন: `end$` (লাইনটি end দিয়ে শেষ হতে হবে)।
- `\b` (Word Boundary): কোনো নির্দিষ্ট **শব্দের সীমানা** তৈরি করে। যেমন: `cat` লিখলে শুধু স্বাধীন শব্দ "cat" মিলবে, "concatenate" বা "catfish"-এর ভেতরের "cat" মিলবে না।

💡 কিভাবে প্র্যাকটিস করবেন?

অনলাইনে প্র্যাকটিস করার জন্য সবচেয়ে সেরা ওয়েবসাইট হলো regex101.com। সেখানে গিয়ে 'Flavor' অপশনে Python, JavaScript বা PCRE সিলেক্ট করে উপরের উদাহরণগুলো নিজে নিজে টাইপ করে টেস্ট করুন!

৫. কুইক রেফারেন্স শিট (সংক্ষেপে মনে রাখার উপায়)

কাজ	RegEx সিনট্যাক্স	উদাহরণ
যেকোনো সংখ্যা ধরা	<code>\d+</code>	123, 999, 0
যেকোনো শব্দ ধরা	<code>\w+</code>	Hello, User_123
ঐচ্ছিক অক্ষর (Optional)	<code>https?</code>	http, https
নির্দিষ্ট ক্যারেক্টার সেট	<code>[aeiou]</code>	যেকোনো ভাওয়েল (Vowel) বর্ণ
রেঞ্জ বা সীমা	<code>[A-Z]</code>	যেকোনো বড় হাতের অক্ষর

কাজ	RegEx সিনট্যাক্স	উদাহরণ
গ্রুপিং (Group)	(cat dog)	cat অথবা dog শব্দ